

POSTECH



TECH CHALLENGE

Tech Challenge é o projeto da fase que engloba os conhecimentos obtidos em todas as disciplinas dela. Esta é uma atividade que, a princípio, deve ser desenvolvida em grupo. É importante atentar-se ao prazo de entrega, uma vez que essa atividade é obrigatória e vale 90% da nota de todas as disciplinas da fase.

Tech Challenge – Predição e Inteligência Analítica para Alfabetização no Brasil

O Tech Challenge é o projeto integrador desta fase e tem como objetivo consolidar os conhecimentos adquiridos nas disciplinas do curso. Trata-se de uma atividade obrigatória, preferencialmente desenvolvida em grupo, cuja pontuação corresponde a 90% da nota final. O desafio propõe a aplicação prática de técnicas analíticas e modelos preditivos em um problema real do contexto educacional brasileiro.

Na Fase 2, vocês foram responsáveis pela construção da pipeline de engenharia de dados e integração das informações relacionadas ao Indicador Criança Alfabetizada no Brasil. Nesta nova etapa, os dados tratados na camada Gold serão utilizados para o desenvolvimento de soluções analíticas e modelos de Machine Learning capazes de gerar inteligência aplicada à tomada de decisão.

A alfabetização infantil é um dos principais indicadores do desenvolvimento educacional e social do país. Entretanto, compreender apenas os dados atuais não é suficiente para apoiar decisões estratégicas. Gestores públicos precisam antecipar riscos, identificar regiões vulneráveis e compreender quais fatores possuem maior impacto nos indicadores educacionais. Nesse contexto, o papel da Ciência de Dados passa a ser fundamental para transformar dados públicos em inteligência analítica aplicada.

O principal objetivo deste desafio será **desenvolver um modelo supervisionado capaz de prever se um aluno será considerado alfabetizado ou não alfabetizado, utilizando variáveis educacionais, territoriais e socioeconômicas**. Os dados utilizados deverão ser provenientes da camada Gold desenvolvida na Fase 2, incluindo informações como indicadores de alfabetização, metas estaduais e municipais, dados territoriais, variáveis socioeconômicas, dados

educacionais complementares e indicadores populacionais. As equipes também poderão enriquecer a base analítica utilizando fontes externas, como IBGE, Censo Escolar, FUNDEB, PNAD e Atlas do Desenvolvimento Humano.

O projeto deverá iniciar com uma análise exploratória dos dados, buscando compreender distribuições, padrões, correlações e possíveis fatores associados ao desempenho educacional. A análise exploratória deverá apoiar diretamente as decisões de modelagem e a construção das hipóteses analíticas do projeto.

Na etapa de modelagem, espera-se que vocês construam uma pipeline completa de Machine Learning, contemplando tratamento de dados, engenharia de atributos, transformação de variáveis e validação estatística dos modelos. Recomenda-se a utilização de pipelines automatizadas utilizando a biblioteca Scikit-learn, aplicando boas práticas utilizadas em ambientes produtivos de Machine Learning.

Sua pipeline deve conter:

- Imputação de valores faltantes para variáveis numéricas;
- Aplicar técnicas de transformação de variáveis numéricas e categóricas;
- Tratamento de data leakage;
- Integração do pré-processamento diretamente ao modelo.
- Treinamento e validação do modelo;
- Validação do modelo garantindo replicabilidade e generalização

Base de Dados

Os dados utilizados deverão ser provenientes da camada Gold construída no Tech Challenge da Fase 2, contendo integrações como:

- Indicador Criança Alfabetizada;
- Metas nacionais e estaduais;
- Metas municipais;
- Dados territoriais;

- Dados socioeconômicos;
- Dados educacionais complementares;
- Indicadores temporais;
- Informações populacionais e regionais.

A equipe poderá enriquecer ainda mais a base utilizando fontes externas como:

- IBGE;
- Censo Escolar;
- FUNDEB;
- Atlas do Desenvolvimento Humano;
- PNAD;
- Cadastro Único;
- Dados socioeconômicos regionais.

Etapas Esperadas do Projeto

Análise Exploratória e Entendimento do Problema

A equipe deverá:

- Compreender o comportamento dos dados;
- Identificar padrões;
- Avaliar distribuições;
- Detectar correlações;
- Analisar variáveis relevantes;
- Formular hipóteses analíticas.

A análise exploratória deverá apoiar diretamente as decisões de modelagem.

Modelagem Supervisionada

Durante o processo de treinamento, a equipe deverá **demonstrar de forma clara toda a pipeline de Machine Learning desenvolvida**, incluindo as etapas de preparação e tratamento dos dados, engenharia de atributos (feature engineering), transformação de variáveis numéricas e categóricas, aplicação de técnicas de feature encoding, tratamento de valores faltantes e integração do pré-processamento diretamente ao pipeline do modelo. Também deverá ser demonstrado como foram evitados problemas de data leakage, garantindo a separação adequada entre os conjuntos de treino, validação e teste.

A modelagem deverá contemplar estratégias de otimização e validação dos modelos, utilizando técnicas com o objetivo de aumentar a capacidade de generalização e reduzir problemas de overfitting.

Além da avaliação das métricas de performance, o projeto deverá explorar a interpretabilidade dos modelos, identificando quais variáveis possuem maior influência na predição da alfabetização. Para isso, recomenda-se a utilização de técnicas como Feature Importance e SHAP Values.

Aplicação Estratégica

Além da modelagem técnica, o projeto deverá responder perguntas de negócio como:

- Quais fatores mais impactam a alfabetização?
- Quais municípios apresentam maior risco educacional?
- Quais regiões possuem padrões semelhantes?
- Como prever municípios que podem não atingir metas futuras?
- Quais variáveis possuem maior influência nos modelos?

O foco não é apenas gerar métricas altas, mas produzir inteligência aplicável ao contexto educacional brasileiro.

Estrutura Mínima do Repositório

📁 tech-challenge-fase3

|

|— 📁 data

|— 📁 notebooks

|— 📁 src

| |— preprocessing

| |— modeling

| |— evaluation

| |— visualization

|

|— 📁 reports

|— 📁 images

|— requirements.txt

|— README.md

|— .gitignore

O projeto deverá demonstrar boas práticas de versionamento utilizando Git, incluindo:

- Histórico de commits,
- Uso de branches,
- Pull requests,
- Documentação das decisões analíticas,
- Organização colaborativa do projeto.

README – Estrutura Esperada

Seu README deverá conter:

- Contexto do problema;
- Objetivo analítico;
- Descrição da base utilizada;
- Etapas de modelagem;
- Escolha do algoritmo;
- Métricas de avaliação;
- Interpretação dos resultados;
- Insights encontrados;
- Limitações do projeto;
- Aplicação prática para políticas públicas;
- Possíveis evoluções futuras.

Entregáveis Finais

A entrega deverá conter:

- Repositório Git completo;
- Código-fonte organizado;
- Notebooks ou scripts;
- README detalhado;
- Documentação técnica;
- Vídeo executivo;
- Pipeline reproduzível;
- Análises e visualizações.

Vídeo Executivo (até 5 minutos)

O grupo deverá gravar um vídeo executivo apresentando:

- O problema educacional;
- Os principais insights;
- O valor estratégico da solução;
- E como os modelos poderiam apoiar políticas públicas educacionais.

A apresentação deverá simular uma reunião executiva com gestores públicos, lideranças ou stakeholders.

Mais do que construir modelos, este desafio busca formar cientistas de dados capazes de transformar dados públicos em inteligência aplicada para tomada de decisão real.

Boa sorte no desenvolvimento do projeto! E não deixem de explorar hipóteses, testar abordagens diferentes e discutir suas ideias com os professores ao longo do processo!



POSTECH